

分类号_____

U D C _____

密级_____

编号 10736 _____

西北师范大学

硕士学位论文

脉冲神经网络的多脉冲定时误差
反向传播算法研究

研究生姓名：巩祖正

指导教师姓名、职称：蔺想红 副教授

专业名称：计算机应用技术

研究方向：计算智能

二〇一三年五月

硕士学位论文

M.D. Thesis

Multi-Spike Timing Error
Backpropagation Algorithm in Spiking
Neural Networks

巩祖正

Gong Zuzheng

西北师范大学研究生学位论文作者信息

论文题目	脉冲神经网络的多脉冲定时误差反向传播算法研究		
姓 名	巩祖正	学 号	2010210835
专业名称	计算机应用技术	答辩日期	2013-05-25
联系电话	15117236387	E_mail	gongzz1988@163.com
通信地址(邮编): 西北师范大学计算机科学与工程学院 (730070)			
备注:			

目录

摘要	I
Abstract.....	II
1 绪论	1
1.1 选题背景及意义	1
1.2 脉冲神经网络监督学习的研究现状	1
1.2.1 基于梯度下降的监督学习.....	2
1.2.2 基于 Hebb 学习规则的监督学习	2
1.3 脉冲神经网络的基本理论	3
1.3.1 脉冲神经元模型概述.....	4
1.3.2 脉冲神经网络的基本结构.....	6
1.3.3 脉冲序列信息编码方案.....	7
1.4 论文内容及组织结构	10
2 多脉冲误差反向传播算法	12
2.1 脉冲神经网络结构	12
2.2 脉冲响应模型	12
2.3 多脉冲误差反向传播算法	13
2.3.1 新型的多脉冲误差函数.....	14
2.3.2 突触权值的梯度下降学习规则.....	14
2.3.3 输出层突触权值的误差梯度计算.....	14
2.3.4 隐含层突触权值的误差梯度计算.....	16
2.4 小结	19
3 脉冲序列的学习过程	20
3.1 单脉冲序列学习任务	20
3.2 多脉冲序列学习任务	22
3.3 多任务脉冲序列学习任务	24
3.4 小结	26
4 非线性模式分类问题	27
4.1 Fisher Iris 分类问题.....	27
4.1.1 实验过程.....	27
4.1.2 实验参数分析.....	29

4.2 Wisconsin 乳腺癌分类问题	30
4.2.1 实验过程.....	30
4.2.2 实验参数分析.....	31
4.3 小结	33
5 总结与展望	34
5.1 总结	34
5.2 研究展望	34
参考文献	36
攻读硕士期间学术成果	39
致谢	40

摘要

最近几年来,随着多层前馈脉冲神经网络监督学习研究的快速发展,越来越多的研究成果表明基于脉冲精确定时编码的脉冲神经网络是神经系统处理信息的基础。很多研究者借鉴传统人工神经网络的误差反向传播算法,给出了脉冲神经网络基于梯度下降的学习规则。而且本文旨在解决多层前馈脉冲神经网络监督学习中的两个基本问题:(1)如何定义多脉冲误差函数以及构建脉冲神经网络多脉冲定时误差反向传播算法;(2)如何设计有效的多脉冲定时信息编码方法以实现对具体问题求解的脉冲神经网络监督学习计算模型。

本文针对多脉冲精确定时编码信息的特点,定义了新型的多脉冲误差函数,并提出了一种新型的基于多脉冲误差反向传播的多层前馈脉冲神经网络监督学习算法。通过构建输出层和隐含层神经元突触权值的梯度下降学习规则,实现了脉冲神经网络突触权值的自动调整。该算法克服了现存学习算法中对输出层神经元仅能发放一个脉冲的限制,可使网络中所有层的神经元发放多个脉冲,提高了应用脉冲神经网络解决复杂问题的能力。

本文通过一组模拟实验展示了多脉冲误差反向传播算法在各种学习情况下,对一系列学习任务的学习能力。首先,通过对单脉冲序列的学习验证了对于给定输入脉冲序列,脉冲神经网络能够训练出一个理想的脉冲序列。其次,通过对多脉冲序列的学习展示了脉冲神经网络能够有效地学习不同的目标脉冲序列。最后,多任务脉冲序列的学习显示了脉冲神经网络对于不同的输入模式能够并行地完成多模式的学习。实验结果表明了该算法能够在误差反向传播学习过程中能够有效地完成不同的学习任务,并实现了对脉冲序列复杂时空模式的学习。

本文将多脉冲定时误差反向传播算法应用到非线性模式分类问题,验证该算法对非线性模式分类问题的求解能力。首先,结合线性脉冲序列编码的特点,分别对 Fisher Iris 数据集和 Wisconsin 乳腺癌数据集的数据进行编码,使该算法分别在不同学习模式下对 Fisher Iris 分类以及 Wisconsin 乳腺癌基准分类问题进行学习。实验表明多脉冲学习的分类准确率比单脉冲学习得到有效地提高。其次,分别对多脉冲神经网络中突触个数、隐藏层神经元个数两个参数进行了分析。实验结果显示突触个数和隐含层神经元个数会影响该算法的学习能力。

关键词 脉冲神经网络; 监督学习; 误差反向传播; 精确定时编码; 分类问题

Abstract

In recent years, with the rapid development of supervised learning algorithms for multi-layered feedforward spiking neural networks, there is a growing recognition that spiking neural networks with precise spike timing encoding is considered as an essential component in information processing by the nervous system. According to traditional error backpropagation algorithm, many studies presented some gradient descent learning rule in spiking neural networks. This thesis motivate to address two fundamental issues which are: (1) how to define multi-spike error function and design multi-spike timing error backpropagation algorithm in spiking neural networks; (2) how to design the effective method of multi-spike timing information encoding to solve specific problems by calculation model of supervised learning in spiking neural networks.

According to the characteristic of encoding information with precise timing of multiple spikes, a new supervised learning algorithm based on multiple spikes error backpropagation is derived by defining new multiple spikes error function in multi-layered feedforward spiking neural networks, which can adjust all synaptic weights of the output layer and the hidden layers using the gradient descent learning rule. The algorithm presented here overcomes some limitations of existing learning algorithms which can only be used for one spike per neuron in the output layer, and it can be applied to neurons firing multiple spikes in all layers and improve the capability of spiking neural networks to solve complex problems.

In a set of experiments we use a set of learning tasks to demonstrate learning ability of the proposed algorithm under various learning scenarios. The learning task of the single spike train demonstrates that the algorithm enables the spiking neural networks to train a desired spike train in response to given input spike trains. Next, we extend the learning task to the multiple spike trains. The result shows that the network performs different desired spike trains. Finally, the learning task of the multitasking spike trains demonstrates that learning multiple patterns can be performed in parallel by different input patterns. The three experiments demonstrate that the algorithm can efficiently perform different learning tasks and implement the complex

spatio-temporal pattern learning of spike trains.

The multi-spike timing error backpropagation algorithm is applied to spiking neural networks to solve non-linear pattern classification problems. We begin with the linear spike train encoding to learn the Fisher iris and the Wisconsin breast cancer datasets under different learning patterns. The two experiments demonstrate that this effectively improves the classification accuracy of multi-spike learning compared to that of single-spike learning. Next, we analyze two parameters of the size of synapses and the size of neurons in the hidden layer. The results show that two parameters influence the learning ability of the proposed algorithm.

Keywords spiking neural network; supervised learning; error backpropagation; precise timing encoding; classification problem

1 绪论

1.1 选题背景及意义

现在的脑科学研究发现,对于机体内各种环境的变化,神经系统均以神经元发放脉冲序列的形式做出响应。而且越来越多的研究成果表明神经系统基于脉冲精确定时编码与处理神经信息的重要性^[1]。应用更具生物真实性的脉冲神经元模型为基本单元构成脉冲神经网络(Spiking Neural Network, SNN),与基于脉冲频率编码信息的传统人工神经网络(Artificial Neural Network, ANN)相比,基于脉冲精确定时特性的脉冲神经网络拥有更强大的计算能力,可以模拟各种神经元信号和任意的连续函数,非常适合于实现大脑神经信号的处理问题^[2, 3]。但是,对于脉冲神经网络的研究仍然处于初级阶段,特别是构建具有广泛适用性的脉冲神经网络学习算法,并将其应用于各种复杂问题的求解,需要研究者持续而卓有成效的工作。

对于脉冲神经网络来说,神经信息输出以脉冲序列的形式表示,神经元内部状态变量及误差函数不再满足连续可微的性质,传统人工神经网络基于梯度下降学习规则的误差反向传播算法已不能直接使用。因此,针对脉冲神经元基于脉冲精确定时编码信息的特点,构建前馈脉冲神经网络的多脉冲定时误差反向传播算法,并将其应用到各种模式分类的实际问题,将面临许多概念与技术上的挑战。本文的研究具有下面两个重要意义:(1) 通过对脉冲神经网络的多脉冲定时误差反向传播算法的研究,丰富了脉冲神经网络研究的学习方法及理论内容。(2) 为脉冲神经网络监督学习的各种应用奠定了坚实的理论基础,为脉冲神经网络监督学习的发展提供了有力的技术支持。

1.2 脉冲神经网络监督学习的研究现状

神经科学最新研究成果表明在人的大脑内存在监督学习,特别是感觉运动神经系统^[4,5]。但是关于哪些生物神经元是监督学习,到现在还没有明确的结论。针对脉冲神经网络的监督学习主要分为两个方向:(1) 基于梯度下降的监督学习;(2) 基于 Hebb 学习规则的监督学习。

1.2.1 基于梯度下降的监督学习

近年来, 关于多层前馈脉冲神经网络监督学习的研究也取得了一些进展。Bothe 等人^[6]首次提出了适用于前馈脉冲神经网络误差反向传播的 SpikeProp 算法, 该算法使用了具有解析表达式的脉冲响应模型, 并为了克服神经元内部状态变量由于脉冲发放而导致的不连续性, 限制所有神经元只能发放一个脉冲。通过脉冲神经网络突触权值的学习, 表明 SpikeProp 算法具有解决非线性问题的能力, 包括对 XOR 问题的求解。Xin 和 Embrechts^[7]通过增加简单的动量项, 加速了 SpikeProp 算法的收敛速度。此外, 通过增加对突触延时、神经元脉冲发放阈值和时间常量等参量基于梯度下降的学习规则, SpikeProp 算法的性能进一步增强, 当求解给定的学习任务时, 具有更小的网络规模和更快的收敛速度^[8]。McKennoch 等人提出了收敛速度更快的 RProp 和 QuickProp 算法^[9], 并进一步将 SpikeProp 算法扩展到一类非线性神经元模型, 构造了 Theta 神经网络的误差反向传播算法^[10]。Wakamatsu 等人^[11]在最速下降方向使用线性搜索方法, 从而提高了脉冲神经网络 SpikeProp 算法学习过程的稳定性。但是, 脉冲神经网络的这些反向传播算法都是用单脉冲编码信息, 即所有神经元在网络模拟过程中只能发放一个脉冲, 这种局限性使 SpikeProp 算法不能实现对复杂问题的有效求解。

对于 SpikeProp 算法更加重要的扩展工作是 Multi-SpikeProp 算法, 这类算法对脉冲神经网络输入层和隐含层神经元的脉冲发放没有限制, 但仍然限制输出层神经元只能发放一个脉冲^[12]。最近, Ghosh-Dastidar 和 Adeli^[13]对于多层前馈多脉冲神经网络, 应用链式规则推导了输出层和隐含层突触权值的梯度下降学习规则, 并将其应用到标准 XOR 问题, 以及更加实际的 Fisher Iris 和脑电图分类问题, 实验结果表明 Multi-SpikeProp 算法比 SpikeProp 算法具有更高的分类准确率。

1.2.2 基于 Hebb 学习规则的监督学习

1949 年, Hebb 在《行为的组织》中提出了 Hebb 学习规则, 他认为如果神经元 A 的轴突与神经元 B 足够接近, 并能反复地或持续地刺激神经元 B 使之发放脉冲, 则神经元 A 的轴突到神经元 B 的突触效能就会增加。该学习规则主要强调突触前/后神经元的协同活动以及引起突触增强的重要性。

Hebb 学习规则为脉冲神经网络的学习奠定了基础。在 Hebb 学习规则的基础上, 很多研究者提出了各种适合脉冲神经网络的监督学习算法。Ponulak^[14]等人

提出了基于Hebb学习规则的ReSuMe算法，该算法通过STDP和anti-STDP学习规则调整突触权值，并适应于各类脉冲神经元模型。但ReSuMe算法只能对输入层和输出层神经元突触权值进行调整，而不像SpikeProp算法那样能够调整脉冲神经网络的每一层突触权值。Grüning和Sporea^[15]将ReSuMe算法应用到含有一层隐含层的脉冲神经网络，使脉冲神经网络能够进行非线性逻辑操作。Glackin^[16]等人把分层的前馈型脉冲神经网络的隐含层看作一个频率滤波器，输入脉冲序列和目标脉冲序列由固定频率的脉冲序列组成，利用ReSuMe算法训练脉冲神经网络的输出层神经元。最近，Sporea和Grüning^[17]运用网络误差反向传播将ReSuMe算法扩展到多层前馈脉冲神经网络中，然而权值的修改不像SpikeProp算法，而是根据STDP和anti-STDP规则进行处理，并使神经元在所用层中发放多脉冲。模拟实验展示了该监督学习算法的灵活性，并允许不同的脉冲定时结构编码。

实际上，生物神经网络在输出层用多脉冲精确定时编码神经信息。因此，要用多层前馈脉冲神经网络解决更为复杂的问题，就必须先确定相应网络可对脉冲序列的复杂时空模式进行学习的误差反向传播算法。鉴于研究中存在的这些问题，本文的研究重点在于：(1) 在定义新型多脉冲误差函数的基础上，设计神经元突触权值基于梯度下降的学习规则，实现多层前馈脉冲神经网络基于多脉冲误差反向传播的监督学习算法。(2) 分析多脉冲定时误差反向传播算法的各参数对学习性能的影响，进一步将所提算法应用到实际的非线性模式分类问题，并分析多脉冲误差反向传播算法中各种参数对学习性能的影响。

1.3 脉冲神经网络的基本理论

脉冲神经网络是一类更加符合生物神经系统的人工神经网络，它由脉冲神经元构成，每个神经元通过发放脉冲序列传输信息。然而要通过脉冲神经网络来模拟神经系统的功能并对实际问题进行求解，首要的问题是构建合适的脉冲神经元模型。对于脉冲神经元模型的建立，从平衡神经元功能特性和计算效率的角度出发，将脉冲神经元的数学建模分为三个层次^[18]：(1) 详细房室模型(Detailed Compartmental Model)，真实的神经元具有在形态和生理两方面都极为复杂的树突树和轴突及其分支，根据树突和轴突形状特征可区分不同类型的细胞。根据Rall^[19]的被动电缆理论和房室建模方法，可建立定量研究树突整合功能的理论框架。房室模型是对电缆理论的补充，数学上房室方法是对非线性的电缆方程的某种有限差分逼近，一般用常微分方程来取代连续电缆方程。对于每一时间间隔，

运用数值方法来解这个系统，它可能包括上千个房室，也就是上千个方程。(2) 缩减房室模型(Reduced Compartmental Model)，缩减房室模型在神经元的功能特性和计算效率之间进行了折衷，仅用一个或几个树突房室来表达神经脉冲在树突与胞体之间的交互。该模型已应用在声音定位^[20]、短程记忆^[21]等研究中。(3) 单房室模型(Single Compartmental Model)。该模型忽略了神经元的形态特征，将神经元抽象为一个点，仅考虑各种离子电流对神经元阈下行为和脉冲生成的影响。

1.3.1 脉冲神经元模型概述

由于单房室模型具有简单的计算特性，单房室脉冲神经元模型被广泛应用于脉冲神经网络的计算研究中。基于对生物神经元不同的认识和理解，同时也基于对不同计算功能的需要，在过去的几十年，出现了很多单房室脉冲神经元的计算模型，下面介绍三种主要的脉冲神经元模型：

(1) Hodgkin-Huxley (简称 HH) 神经元模型

1952 年，Hodgkin 和 Huxley^[22,23] 通过研究神经元膜电位和离子电导变化的关系奠定了神经冲动和传导的实验和理论基础，它揭示了各种可兴奋性细胞的基本规律。经过大量实验和分析，他们确认神经轴突膜上具有 Na^+ 通道和 K^+ 通道，这些通道强烈地依赖于膜电位且电导不是恒定的。这是由于两通道中存在着几个为膜中有机分子所控制的门，这些门开关的概率与膜电位有关。门开与关的频率与膜电位有关。此外，膜中还有包括 Cl^- 在内的其它离子的通道所形成的漏电流。HH 神经元模型给出了描述神经元兴奋性的四维耦合微分方程组，如下：

$$\begin{aligned} C_m \frac{dV}{dt} &= -g_L(V - V_L) - \bar{g}_{\text{Na}} m^3 h (V - V_{\text{Na}}) - \bar{g}_K n^4 (V - V_K) + I \\ \frac{dm}{dt} &= \alpha_m(V)(1 - m) - \beta_m(V)m \\ \frac{dh}{dt} &= \alpha_h(V)(1 - h) - \beta_h(V)h \\ \frac{dn}{dt} &= \alpha_n(V)(1 - n) - \beta_n(V)n \end{aligned} \quad (1.1)$$

其中， V 表示膜电位， I 表示突触输入或外部注入电流， C_m 表示膜电容， g_L 表示漏电导， V_L 表示漏电逆转电位，也称静息电位。 \bar{g}_{Na} 和 \bar{g}_K 分别表示 Na^+ 与 K^+ 通道最大电导值， V_{Na} 和 V_K 分别表示对应的逆转电位。 Na^+ 电流由三个活化门 m 和一个去活化门 h ，控制 K^+ 电流由四个活化门 n 控制。这些门控变量通常随膜电位而变化，神经元模型能够表达神经元兴奋性的很多特性，是电生理、膜生物物理和计

算神经科学等学科的基础。Traub 和 Miles^[24]给出了修正的表达式如下所示：

$$\begin{aligned}
\alpha_m(V) &= 0.32(13 - V + V_T) / [\exp((13 - V + V_T)/4) - 1] \\
\beta_m(V) &= 0.28(V - V_T - 40) / [\exp((V - V_T - 40)/5) - 1] \\
\alpha_h(V) &= 0.128 \exp((17 - V + V_T)/18) \\
\beta_h(V) &= 4 / [\exp((40 - V + V_T)/5) + 1] \\
\alpha_n(V) &= 0.032(15 - V + V_T) / [\exp((15 - V + V_T)/5) - 1] \\
\beta_n(V) &= 0.5 \exp((10 - V + V_T)/40)
\end{aligned} \tag{1.2}$$

式中 V_T 用来调节膜电位阈值。

(2) Integrate-and-Fire (简称 IF) 神经元模型

1907 年, Lapicque^[25]用电子线路模拟神经元的神经生理现象, 构造了最早的神经元模型, 当时, 人们对神经元动作电位形成机制的认识还很不清楚。Integrate-and-Fire^[26] 神经元模型表示累积器 Integrate-and-Fire 神经元模型可用理想的一阶微分方程描述:

$$\begin{aligned}
\frac{dV}{dt} &= a - bV + I \\
V &\geq V_{thresh}, V \leftarrow V_{thresh}
\end{aligned} \tag{1.3}$$

其中, V 表示膜电位, a 和 b 表示神经元模型的参数。当神经元的膜电位 V 到达阈值电位 V_{thresh} 时, 神经元发放一个脉冲, 并将 V 复位到 V_{reset} 。Integrate-and-Fire 神经元模型表现为第 1 类兴奋性神经元, 脉冲可以以任意低的频率产生, 并且频率随输入电流的增大而增大。都具有固定的点火阈值和复位机制, 静息状态具有唯一的稳定的结点。因为它是简单的线性模型, 不仅可以通过膜电位的解析式对神经元的性质进行定量研究, 而且可以应用事件驱动模拟策略实现脉冲神经网络的精确模拟。所以长期以来在神经计算领域得到了广泛应用。

(3) 脉冲响应模型 (Spike Response Model, 简称 SRM)

SRM 模型表现了与具有生物可解释性的 HH 神经元模型相似的动力学特性。该模型的脉冲神经元膜电位 u_j 超过阈值 θ 时, 神经元 j 就会产生一个脉冲, 然后膜电位 u_j 减小并恢复到静息电位。因此, 神经元 j 的膜电位 u 在时间 t 的函数可表示为:

$$u_j(t) = \sum_{i \in \Gamma_i} \sum_{t_i^s \in F_i} w_{ij} \varepsilon(t - t_i^s - d_{ij}) + \sum_{t_j^f \in F_j} \rho(t - t_j^f) \tag{1.4}$$

公式(1.4)中的 ε 表示神经元 j 对输入的突触前脉冲的反应, ρ 函数表示神经元的

不应期过程。此公式称为 SRM 模型^[27,28]。

1.3.2 脉冲神经网络的基本结构

同人工神经网络一样脉冲神经网络同样分为三种拓扑结构。他们分别是前馈型网络结构，递归型网络结构和混合型网络结构。

(1) 前馈型结构 (Feed-forward networks)

多层前馈网络结构中每个脉冲神经元只与前一层的脉冲神经元相连接，第一层是脉冲神经网络的输入层，它不包含神经元的计算，只是代表网络的输入。脉冲神经网络的输入是各输入神经元的脉冲序列。脉冲神经网络的最后一层为输出层，该层负责输出脉冲神经网络的计算结果。除输入层和输出层之外的其他各层称为隐含层，该层只能接受输入层的脉冲序列，也只能向输出层传输脉冲序列。

脉冲神经网络不同于 ANN，它通常采用多突触连接方式，两个脉冲神经元之间有多个突触的连接，每个突触具有不同的突触权值和延时。这种多突触的不同延时特性能够使突触前神经元输入的脉冲序列在更长的时间范围对突触后神经元的脉冲序列发放产生影响。

(2) 递归型结构 (Recurrent networks)

递归网络已经被广泛的应用于嵌入式系统。它在分析动力学系统中很适合被用做模板。另一方面，相对于前馈型网络，递归网络很难有效的应用到脉冲神经网络的监督学习中。

在人脑的一部分神经元中被发现一些稀疏结构类似于递归网络结构，被称为神经微电路^[29]，如图 1.1 所示。神经微电路的脉冲模板的性能和计算能力被人们所发现。




图1.1 神经微电路

(3) 混合型结构(Hybrid networks)

下面主要介绍两种混合型网络结构：

同步发放链(Synfire Chain)^[30]被认为是用来表示不同延时事件之间关系的一种重要机制,它是一种多层结构,该结构的神经元发放的脉冲序列能够从一层(脉冲集合)依次发放到下一层(子集)信息。在同步发放链的各个子层之间采用的是前馈型结构。而子层的内部则采用的是递归性结构,如图1.2所示。因此,我们把同步发放链定义为混合型结构。




图1.2 同步发放链的多层结构

最近, Maass 和 Colleagues^[31, 32]提出了一种新型的概念框架称之为液态机 (Liquid State Machine, LSM), 它利用递归神经网络的性能, 减少了发放过程中链接困难。这种液态机机制由一个非常大的复杂递归神经网络和神经微电路组成, 这种神经微电路仅仅通过训练合适的输出突触权值获得理想的目标脉冲序列, 如图1.3所示。




图 1.3 液态机结构

1.3.3 脉冲序列信息编码方案

神经元发放的信号包含了一系列的脉冲序列,它分为定期发放和不定期发放,如图 1.4 所示。在神经系统中,每一毫秒中枢神经系统的感知神经元会发放无数的脉冲信号,根据这些数据中枢神经系统来执行特定的操作,有时候这种决策是每十毫秒来完成一次的。




图 1.4 神经信息编码和解码示例

这个过程能作为快速的信息加工过程，我们想了解如下几个问题：信息在神经信号中是如何进行编码的？神经信号通过什么参数来运载一些重要信息的？信号的瞬时分辨率是如何做出精确计算的？

对于脉冲序列的信息编码问题，借鉴生物神经元的信息编码方法，接下来我们将介绍几种脉冲神经网络的脉冲序列编码方法：

(1) Time-to-first-spike 编码

Time-to-first-spike 编码是一种比较简单的将模拟数据转变为脉冲时间的信息编码方法。它假设神经元只发放一个脉冲，产生脉冲的时刻与模拟数据值成比例。Thorpe 等人^[33]通过生物实验发现大脑中的每个处理步骤中，各神经元最多只能发放一个脉冲。Time-to-first-spike 编码方法广泛应用到研究生物神经元的信息处理和脉冲神经网络的数据编码方面。图 1.5 给出了 Time-to-first-spike 编码策略的示意图。




图 1.5 Time-to-first-spike 编码策略

(2) 相位编码

通过研究发现，人脑中许多神经系统的神经元用脉冲相位编码方法处理脉冲

序列。如果输入脉冲序列信号各周期的波形不变，那么神经元产生的脉冲序列相位也会出现周期模式^[28,34]，如图 1.6 所示。每个神经元在一个周期内只产生脉冲时间，然后整个时间过程的模拟数据值的变化可以将每个时间周期连起来得到的脉冲序列表示。




图 1.6 相位编码策略

(3) 线性编码

线性编码^[16]是一种简单的将模拟数据转化为脉冲序列的编码方法。首先，将模拟的数据值归一化，并线性编码到一个频率范围内。然后，将每个频率值转化为一个时间区间内的脉冲序列。这种方法应用简单，比较适合固定且有规律的数据集。

(4) 群体编码

群体编码^[35]是将数据的信息分布到多个神经元的脉冲时间中的一种编码方法。如文献[3]中采用高斯接收域的方法进行脉冲序列编码，该方法体现了生物神经元稀疏发放特性^[8]。

假设用 m 个神经元编码一个取值范围为 $[I_{\min}, I_{\max}]$ 的变量 x ，时间编码的具体步骤如下：

(1) 确定 m 个 ($m > 2$) 神经元对应的高斯函数，神经元 i 对应的高斯函数的均值和方差分别设置为：

$$\mu = I_{\min} + \frac{2i-3}{2} \cdot \frac{I_{\max} - I_{\min}}{m-2}, \quad i = 1, 2, \dots, m \quad (1.5)$$

$$\sigma = \frac{1}{\beta} \cdot \frac{I_{\max} - I_{\min}}{m-2}, \quad \beta = 1.5 \quad (1.6)$$

与文献[36]中介绍的相同。

(2) 计算变量的值对应的 m 个高斯函数的值。如果脉冲神经网络的输入由 n

个变量组成，每个变量分别计算 m 个高斯函数的值，则一共得到 $n \times m$ 个 $[0,1]$ 区间的高斯函数值。

(3) 根据对应变量 $0 \sim 1$ 取值的时间编码间隔，将高斯函数值转为脉冲时间。如果时间编码间隔为 10 ms ，对脉冲时间的赋值如下：若高斯函数值为 1 ，则脉冲时间 $t=0 \text{ ms}$ ，若脉冲时间值为 0 ，则脉冲时间 $t=10 \text{ ms}$ ，并对得到的脉冲时间取整。另外，较晚输入的脉冲一般不会使神经元发放脉冲，这里用 ∞ 代替大于 $t=9 \text{ ms}$ 的脉冲输入，表示该输入神经元没有输入脉冲，这样可以使数据编码更稀疏，便于计算。图 1.7 显示了在 $[4.3, 7.9]$ 之间取值的输入变量 x 的编码。 x 的值编码为 12 个神经元的脉冲时间，图 1.7 中 $x=4.9$ 对应于脉冲时间为 $\{\infty, 8, 0, 5, \infty, \infty, \infty, \infty, \infty, \infty, \infty, \infty\}$ 。




图 1.7 群体编码策略

1.4 论文内容及组织结构

本文针对多脉冲编码神经信息的特征，以及目前多层前馈脉冲神经网络误差反向传播算法研究中存在的问题，提出一些切实可行的解决办法，提高应用脉冲神经网络解决复杂问题的能力。主要研究内容包括以下三个方面：(1) 脉冲神经网络的多脉冲定时误差反向传播算法的构建。通过定义新型的多脉冲定时误差函数，构建输出层和隐含层神经元突触权值的梯度下降学习规则，实现脉冲神经网络突触权值的自动调整。(2) 多脉冲定时误差反向传播算法的学习能力及过程分析。具体包括该算法对单脉冲序列、多脉冲序列及多任务脉冲序列的学习能力。(3) 多脉冲定时误差反向传播算法对模式分类问题的求解。将该算法应用到实际的模式分类问题，如 Fisher Iris 分类、Wisconsin 乳腺癌分类等标准测试数据集，验证所提算法的有效性。

本文的研究内容分为五章，各章要点简述如下：

第 1 章 绪论 首先，介绍了本文选题背景及意义，并对脉冲神经网络监督学习的研究现状进行概括。其次，分别对脉冲神经元模型、脉冲神经网络结构以及脉冲神经网络信息编码方法进行综述。最后，说明了论文的研究内容及组织结构。

第 2 章 多脉冲误差反向传播算法 结合前馈型脉冲神经网络结构的特点以及 SRM 神经元模型动力学特性，通过定义新型的多脉冲定时误差函数，并提出了一种新型的基于多脉冲误差反向传播的多层前馈脉冲神经网络监督学习算法。该算法实现了脉冲神经网络的监督学习。

第 3 章 脉冲序列的学习过程 结合多脉冲定时误差反向传播算法，分别对单脉冲序列、多脉冲序列以及多任务脉冲序列的学习能力及过程进行分析。

第 4 章 非线性模式分类问题 将多脉冲定时误差反向传播算法应用到实际的模式分类问题，如 Fisher Iris 分类和 Wisconsin 乳腺癌分类标准测试数据集，验证所提算法对模式分类问题的求解能力。

第 5 章 总结与期望 对全文进行总结，并对今后可能的研究方向进行展望。

2 多脉冲误差反向传播算法

2.1 脉冲神经网络结构

类似传统的人工神经网络结构，脉冲神经网络也可以由脉冲神经元构成前馈网络、递归网络等各种网络结构。本文采用的是多层前馈型网络结构，网络采用全连接方式，如图 2.1(a)所示。例如，第 l 层的神经元 j 作为突触后神经元和前一层的 $l+1$ 中的所有神经元 i 连接，总共有 N_{l+1} 个突触前神经元(网络中层的表示采用向后编码的方式，输出层标记为第 1 层)。

本文中脉冲神经网络采用多突触连接的网络结构，如图 2.1(b)所示。两个神经元之间由多个突触连接，每个突触具有不同的延时和连接权值。假设突触前神经元到突触后神经元的突触延时都具有相同的取值方式，并用 d^k 表示第 k 个突触的延时。用 w_{ij}^k 表示从突触前神经元 i 到突触后神经元 j 对应的突触权值， $k \in [1, K]$ ，其中 K 为一个常量。




图 2.1 (a) 脉冲神经网络结构; (b) 神经元之间不同延时多突触的表示

2.2 脉冲响应模型

本文采用了具有解析表达式的 SRM 模型，该模型为分析脉冲神经网络的动态特性和学习过程提供了有益的理论依据。假设 t_i^g 表示网络中第 $l+1$ 层神经元 i 的第 g 个脉冲的发放时间， G_i 表示神经元 i 发放脉冲的总数($g \in [1, G_i]$)，第 l 层的神经元 j 的膜电位 u 为 $l+1$ 层中所有神经元发放脉冲的突触后电位的叠加。当神经元 j 的膜电位达到阈值 θ 时，神经元 j 发放一个脉冲并使神经元处于不应期，神经元 j 发放脉冲的时间表示为 t_j^o ， O_j 表示神经元 j 的脉冲数($o \in [1, O_j]$)。因此，

神经元 j 的膜电位 u 在时间 t 的函数可表示为^[12,37]:

$$u_j(t) = \sum_{i=1}^{N_{i+1}} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t - t_i^g - d^k) + \sum_{o=1}^{O_j} \rho(t - t_j^o) \quad (2.1)$$

公式(2.1)中的 ε 表示脉冲响应函数, 描述了突触前神经元发放的单脉冲对突触后神经元状态变量造成的影响, 如图 2.2 所示。本文中脉冲响应函数用 α 函数的形式计算^[27], 具体可表示为:

$$\varepsilon(t) = \begin{cases} \frac{t}{\tau} e^{1-\frac{t}{\tau}} & \text{当 } t > 0 \\ 0 & \text{当 } t \leq 0 \end{cases} \quad (2.2)$$

其中, τ 表示神经元突触后电位的时间衰减常量, 其值的大小决定了脉冲响应函数的形状。




图 2.2 突触前神经元 i 发放的脉冲对突触后神经元 j 状态变量的影响

本文中, ρ 函数表示神经元的不应期过程, 可表示为:

$$\rho(t) = \begin{cases} -2\theta e^{-\frac{t}{\tau_R}} & \text{当 } t > 0 \\ 0 & \text{当 } t \leq 0 \end{cases} \quad (2.3)$$

其中, θ 表示神经元的阈值, τ_R 表示时间衰减常量, 决定了神经元不应期函数的形状。当 t 在区间 $(0, \infty)$ 取值时, 不应期函数 ρ 为负值。当 $t \rightarrow 0$ 时, 函数的最小值为 -2θ , 当 $t \rightarrow \infty$ 时, 函数值逐渐增大到 0。

2.3 多脉冲误差反向传播算法

脉冲神经网络监督学习的目标是对于输入神经元任意给定的脉冲序列模式, 通过突触权值的调整, 最终输出神经元发放所要求的目标脉冲序列模式。因此, 脉冲神经网络多脉冲误差反向传播算法的关键是定义恰当的多脉冲误差函数, 以及与之相适应的突触权值梯度下降学习规则。

2.3.1 新型的多脉冲误差函数

对于任意给定的输入脉冲序列，脉冲神经网络输出层神经元 j 发放的脉冲序列为 $S_j^o(t)$ ，相应的目标脉冲序列为 $S_j^d(t)$ 。根据最小平方和误差函数，脉冲神经网络的多脉冲误差函数可定义为：

$$E = \frac{1}{2} \sum_{j=1}^{N_1} \sum_{o=1}^{O_j} (t_j^o - t_j^d)^2 \quad (2.4)$$

其中， t_j^o 表示实际脉冲的发放时间， t_j^d 表示目标脉冲的发放时间， N_1 表示输出层神经元的数量， O_j 表示输出层第 j 个神经元实际发放的脉冲总数。

当实际脉冲数和目标脉冲数相等时，多脉冲误差函数计算中的脉冲一一对应。而当实际脉冲数和目标脉冲数不同时，多脉冲误差函数的计算进行如下两种调整：(1)当实际脉冲数比目标脉冲数少时，实际发放的最后一个脉冲总是和目标脉冲序列中多余的脉冲进行比较。可以认为实际脉冲序列中的最后一个脉冲多次发放，这种多次发放的脉冲数计入输出层神经元实际发放的脉冲总数。(2)当实际脉冲数比目标脉冲数多时，实际脉冲序列中多余的脉冲都和目标脉冲序列的最后一个脉冲进行比较。可以认为目标脉冲序列中的最后一个脉冲多次发放，这时输出层神经元实际发放的脉冲总数不变。

2.3.2 突触权值的梯度下降学习规则

应用误差反向传播算法对所有的突触权值学习时，使用 δ 更新规则进行调整。从突触前神经元 i 到突触后神经元 j 的第 k 个突触的权值计算如下：

$$\Delta w_{ij}^k = -\eta \nabla E_{ij}^k \quad (2.5)$$

其中， η 表示学习率， ∇E_{ij}^k 表示多脉冲误差函数 E 对于突触权值 w_{ij}^k 的梯度计算值。根据突触所在层的不同将学习规则分成两部分，分别为输出层与隐含层突触权值的梯度下降学习规则。

2.3.3 输出层突触权值的误差梯度计算

应用多脉冲误差函数和链式规则，可计算最后隐含层中的神经元 i 到输出层神经元 j 的第 k 个突触权值的误差梯度，即输出层的梯度下降学习规则表示为：

$$\nabla E_{ij}^k = \frac{\partial E}{\partial w_{ij}^k} = \sum_{o=1}^{O_j} \frac{\partial E}{\partial t_j^o} \frac{\partial t_j^o}{\partial w_{ij}^k} \quad (2.6)$$

实际上，总的误差梯度为输出层神经元 j 在所有脉冲发放时刻 $t = t_j^o$ 的误差梯度的累加， $o \in [1, O_j]$ 。

公式(2.6)右边的第一个偏导项表示多脉冲误差函数 E 对于输出神经元 j 在脉冲发放时刻 $t = t_j^o$ 的导数，可计算如下：

$$\frac{\partial E}{\partial t_j^o} = \frac{\partial \left[\frac{1}{2} \sum_{j=1}^{N_1} \sum_{o=1}^{O_j} (t_j^o - t_j^d)^2 \right]}{\partial t_j^o} = t_j^o - t_j^d \quad (2.7)$$

由于 $u_j(t_j^o)$ 是 t_j^o 的函数，而 $u_j(t_j^o)$ 又与 w_{ij}^k 相关，则公式(2.6)右边的第二个偏导项可由下面链式规则得到：

$$\frac{\partial t_j^o}{\partial w_{ij}^k} = \frac{\partial t_j^o}{\partial u_j(t_j^o)} \frac{\partial u_j(t_j^o)}{\partial w_{ij}^k} \quad (2.8)$$

由于脉冲产生时刻即是神经元膜电位超过阈值的时刻，所以无法直接求得脉冲时间对膜电位的偏导，但在 Bohte 等人提出的 SpikeProp 算法中解决了求这个偏导的问题^[3]。他们假设在 $t = t_j^o$ 附近一个足够小的范围内，膜电位 u 可以用一个 t 的线性函数逼近。Yang 等人进一步从理论上证明了即使没有线性假设该偏导求解公式的正确性^[38]。所以公式(2.8)右边的第一个偏导项可表示为：

$$\frac{\partial t_j^o}{\partial u_j(t_j^o)} = \frac{-1}{\partial u_j(t_j^o) / \partial t_j^o} \quad (2.9)$$

公式(2.9)的分母项计算如下：

$$\begin{aligned} \frac{\partial u_j(t_j^o)}{\partial t_j^o} &= \frac{\partial \left[\sum_{i=1}^{N_2} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) + \sum_{o'=1}^{O_j} \rho(t_j^o - t_j^{o'}) \right]}{\partial t_j^o} \\ &= \sum_{i=1}^{N_2} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) \left(\frac{1}{t_j^o - t_i^g - d^k} - \frac{1}{\tau} \right) - \sum_{o'=1}^{O_j} \frac{\rho(t_j^o - t_j^{o'})}{\tau_R} \end{aligned} \quad (2.10)$$

将公式(2.10)代入公式(2.9)，可得：

$$\frac{\partial t_j^o}{\partial u_j(t_j^o)} = \frac{-1}{\sum_{i=1}^{N_2} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) \left(\frac{1}{t_j^o - t_i^g - d^k} - \frac{1}{\tau} \right) - \sum_{o'=1}^{O_j} \frac{\rho(t_j^o - t_j^{o'})}{\tau_R}} \quad (2.11)$$

而公式(2.8)右边的第二个偏导项可表示为：

$$\frac{\partial u(t_j^o)}{\partial w_{ij}^k} = \frac{\partial \left[\sum_{i=1}^{N_2} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) + \sum_{o'=1}^{O_j} \rho(t_j^o - t_j^{o'}) \right]}{\partial w_{ij}^k} \quad (2.12)$$

由于任何一个突触的权值与其它突触的权值相互独立，需在计算中去掉 i 和 k 对应的累加部分，并且脉冲响应函数 ε 不依赖于突触的权值，因此公式(2.12)可计算如下：

$$\frac{\partial u(t_j^o)}{\partial w_{ij}^k} = \sum_{g=1}^{G_i} \varepsilon(t_j^o - t_i^g - d^k) + \sum_{o'=1}^{O_j} \frac{\partial \rho(t_j^o - t_j^{o'})}{\partial w_{ij}^k} \quad (2.13)$$

输出层神经元可以发放多个脉冲，突触权值影响脉冲的发放时间，对于每一个脉冲发放所表示的不应期项由下面的链式规则计算：

$$\frac{\partial \rho(t_j^o - t_j^{o'})}{\partial w_{ij}^k} = \frac{\partial \rho(t_j^o - t_j^{o'})}{\partial t_j^{o'}} \frac{\partial t_j^{o'}}{\partial w_{ij}^k} \quad (2.14)$$

因此根据公式(2.14)，可得公式(2.8)右边的第二个偏导项的计算公式：

$$\frac{\partial u(t_j^o)}{\partial w_{ij}^k} = \sum_{g=1}^{G_i} \varepsilon(t_j^o - t_i^g - d^k) + \sum_{o'=1}^{O_j} \frac{\rho(t_j^o - t_j^{o'})}{\tau_R} \frac{\partial t_j^{o'}}{\partial w_{ij}^k} \quad (2.15)$$

将公式(2.11)、(2.15)代入公式(2.8)，可得：

$$\frac{\partial t_j^o}{\partial w_{ij}^k} = \frac{-\sum_{g=1}^{G_i} \varepsilon(t_j^o - t_i^g - d^k) - \sum_{o'=1}^{O_j} \frac{\rho(t_j^o - t_j^{o'})}{\tau_R} \frac{\partial t_j^{o'}}{\partial w_{ij}^k}}{\sum_{i=1}^{N_2} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) \left(\frac{1}{t_j^o - t_i^g - d^k} - \frac{1}{\tau} \right) - \sum_{o'=1}^{O_j} \frac{\rho(t_j^o - t_j^{o'})}{\tau_R}} \quad (2.16)$$

可以看到公式(2.16)这个方程是递归的，偏导项 $\partial t_j^o / \partial w_{ij}^k$ 被所有的 $\partial t_j^{o'} / \partial w_{ij}^k$ 表示，其中 $o' < o$ 。因此对于 $\partial t_j^o / \partial w_{ij}^k$ 的求导，首先从第一个脉冲计算，然后第二个脉冲，以此类推。

总之，将公式(2.7)和(2.16)代入公式(2.6)，就可计算多脉冲误差梯度 ∇E_{ij}^k ，从而调整输出层神经元突触的权值。

2.3.4 隐含层突触权值的误差梯度计算

对于仅包含一个隐层的脉冲神经网络，使用链式规则可计算输入层神经元 h 和隐含层 $l=2$ 中神经元 i 的第 k 个突触权值的误差梯度，即隐含层突触权值的梯度下降学习规则表示为：

$$\nabla E_{hi}^k = \frac{\partial E}{\partial w_{hi}^k} = \sum_{g=1}^{G_i} \frac{\partial E}{\partial t_i^g} \frac{\partial t_i^g}{\partial w_{hi}^k} \quad (2.17)$$

其中 t_i^g 表示隐含层神经元 i 的第 g 个脉冲的发放时间， G_i 表示神经元 i 发放脉冲

的总数($g \in [1, G_i]$)。

首先计算公式(2.17)右边第一个偏导项, 即多脉冲误差函数 E 对于隐含层神经元 i 在脉冲发放时刻 $t = t_i^g$ 的导数, 这个导数值与神经元 i 连接的所有突触后神经发放的脉冲序列相关, 因此这个偏导项的计算可表示为:

$$\frac{\partial E}{\partial t_i^g} = \sum_{j=1}^{N_1} \sum_{o=1}^{O_j} \frac{\partial E}{\partial t_j^o} \frac{\partial t_j^o}{\partial t_i^g} \quad (2.18)$$

公式(2.18)右边第一个偏导项根据公式(2.7)计算可得, 而右边第二个偏导项应用链式规则可扩展为:

$$\frac{\partial t_j^o}{\partial t_i^g} = \frac{\partial t_j^o}{\partial u_j(t_j^o)} \frac{\partial u_j(t_j^o)}{\partial t_i^g} \quad (2.19)$$

公式(2.19)右边第一个偏导项根据公式(2.11)计算可得, 而右边第二个偏导项可以表示为:

$$\frac{\partial u_j(t_j^o)}{\partial t_i^g} = \frac{\partial \left[\sum_{i=1}^{N_2} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) - \sum_{o'=1}^{O_j} \rho(t_j^o - t_j^{o'}) \right]}{\partial t_i^g} \quad (2.20)$$

由于隐含层神经元 i 的脉冲发放时间 t_i^g 与隐含层中其它神经元的脉冲发放时间无关, 并且与该神经元的其它脉冲发放时间相互独立, 因此在计算中去掉 i 和 g 对应的累加部分, 公式(2.20)可计算如下:

$$\frac{\partial u_j(t_j^o)}{\partial t_i^g} = - \sum_{k=1}^K w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) \left(\frac{1}{t_j^o - t_i^g - d^k} - \frac{1}{\tau} \right) + \sum_{o'=1}^{O_j} \frac{\partial \rho(t_j^o - t_j^{o'})}{\partial t_i^g} \quad (2.21)$$

隐含层神经元 i 在时间 t_i^g 发放的脉冲输入到输出层神经元 j 后, 对于神经元 j 的脉冲发放时间产生影响, 其中 $t_j^{o'} > t_i^g$ 。对于神经元 j 每一个脉冲发放所表示的不应期项由下面的链式规则计算:

$$\frac{\partial \rho(t_j^o - t_j^{o'})}{\partial t_i^g} = \frac{\partial \rho(t_j^o - t_j^{o'})}{\partial t_j^{o'}} \frac{\partial t_j^{o'}}{\partial t_i^g} \quad (2.22)$$

结合公式(2.19)、(2.21)和(2.22), 可得 $\partial t_j^o / \partial t_i^g$ 的计算公式如下:

$$\frac{\partial t_j^o}{\partial t_i^g} = \frac{\sum_{k=1}^K w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) \left(\frac{1}{t_j^o - t_i^g - d^k} - \frac{1}{\tau} \right) - \sum_{o'=1}^{O_j} \frac{\rho(t_j^o - t_j^{o'})}{\tau_R} \frac{\partial t_j^{o'}}{\partial t_i^g}}{\sum_{i=1}^{N_2} \sum_{k=1}^K \sum_{g=1}^{G_i} w_{ij}^k \varepsilon(t_j^o - t_i^g - d^k) \left(\frac{1}{t_j^o - t_i^g - d^k} - \frac{1}{\tau} \right) - \sum_{o'=1}^{O_j} \frac{\rho(t_j^o - t_j^{o'})}{\tau_R}} \quad (2.23)$$

可以看到公式(2.23)这个方程也是递归的, 偏导数 $\partial t_j^o / \partial t_i^g$ 被所有的 $\partial t_j^{o'} / \partial t_i^g$ 表示,

其中 $o' < o$ 。同样，对 $\partial t_j^o / \partial t_i^s$ 的求导，从第一个脉冲计算，然后第二个脉冲，以此类推。此外，当 $t_j^o \leq t_i^s$ 时， $\partial t_j^o / \partial t_i^s = 0$ 。

公式(2.17)右边第二个偏导项的计算同输出层中突触权值的推导过程类似，使用下面的链式规则：

$$\frac{\partial t_i^s}{\partial w_{hi}^k} = \frac{\partial t_i^s}{\partial u_i(t_i^s)} \frac{\partial u_i(t_i^s)}{\partial w_{hi}^k} \quad (2.24)$$

公式(2.24)右边第一个偏导项计算如下：

$$\begin{aligned} \frac{\partial t_i^s}{\partial u_i(t_i^s)} &= \frac{-1}{\partial u_i(t_i^s) / \partial t_i^s} \\ &= \frac{-1}{\partial \left[\sum_{h=1}^{N_{l+1}} \sum_{k=1}^K \sum_{f=1}^{F_h} w_{hi}^k \varepsilon(t_i^s - t_h^f - d^k) + \sum_{g'=1}^{G_i} \rho(t_i^s - t_i^{g'}) \right] / \partial t_i^s} \\ &= \frac{-1}{\sum_{h=1}^{N_{l+1}} \sum_{k=1}^K \sum_{f=1}^{F_h} w_{hi}^k \varepsilon(t_i^s - t_h^f - d^k) \left(\frac{1}{(t_i^s - t_h^f - d^k)} - \frac{1}{\tau} \right) - \sum_{g'=1}^{G_i} \frac{\rho(t_i^s - t_i^{g'})}{\tau_R}} \end{aligned} \quad (2.25)$$

同公式(2.15)的计算过程类似，公式(2.24)右边第二个偏导项可计算如下：

$$\begin{aligned} \frac{\partial u_i(t_i^s)}{\partial w_{hi}^k} &= \frac{\partial \left[\sum_{h=1}^{N_{l+1}} \sum_{k=1}^K \sum_{f=1}^{F_h} w_{hi}^k \varepsilon(t_i^s - t_h^f - d^k) + \sum_{g'=1}^{G_i} \rho(t_i^s - t_i^{g'}) \right]}{\partial w_{hi}^k} \\ &= \sum_{f=1}^{F_h} \varepsilon(t_i^s - t_h^f - d^k) + \sum_{g'=1}^{G_i} \frac{\rho(t_i^s - t_i^{g'})}{\tau_R} \frac{\partial t_i^{g'}}{\partial w_{hi}^k} \end{aligned} \quad (2.26)$$

将公式(2.25)、(2.26)代入公式(2.24)，可得偏导项 $\partial t_i^s / \partial w_{hi}^k$ 的递归计算公式：

$$\frac{\partial t_i^s}{\partial w_{hi}^k} = \frac{-\sum_{f=1}^{F_h} \varepsilon(t_i^s - t_h^f - d^k) - \sum_{g'=1}^{G_i} \frac{\rho(t_i^s - t_i^{g'})}{\tau_R} \frac{\partial t_i^{g'}}{\partial w_{hi}^k}}{\sum_{h=1}^{N_{l+1}} \sum_{k=1}^K \sum_{f=1}^{F_h} w_{hi}^k \varepsilon(t_i^s - t_h^f - d^k) \left(\frac{1}{(t_i^s - t_h^f - d^k)} - \frac{1}{\tau} \right) - \sum_{g'=1}^{G_i} \frac{\rho(t_i^s - t_i^{g'})}{\tau_R}} \quad (2.27)$$

总之，将公式(2.18)和(2.27)代入公式(2.17)，就可计算多脉冲误差梯度， ∇E_{hi}^k ，从而调整隐含层神经元突触的权值。此外，对于包含多个隐含层的脉冲神经网络，隐含层神经元突触权值的误差梯度计算可作类似的扩展。

2.4 小结

首先，在分析了前馈型脉冲神经网络结构特点以及 SRM 神经元模型的动力学特性的基础上，结合新型的多脉冲定时误差函数，提出了一种新型的基于多脉冲误差反向传播的多层前馈脉冲神经网络监督学习算法。其次，结合新型的多脉冲定时误差函数，构建了脉冲神经网络突触权值的梯度下降学习规则，使脉冲神经网络的突触权值自动调整。使网络中所有层的神经元发放多个脉冲，提高了应用脉冲神经网络解决复杂问题的能力。最后，根据突触所在层的不同分别对输出层和隐含层突触权值的梯度下降学习规则进行推导，使脉冲神经网络对于输入神经元任意给定的脉冲序列模式，通过突触权值的调整，最终输出神经元发放所要求的目标脉冲序列模式。该算法克服了现存学习算法中对输出层神经元仅能发放一个脉冲的限制，使网络中所有层的神经元发放多个脉冲，提高了应用脉冲神经网络解决复杂问题的能力。

3 脉冲序列的学习过程

本章展示了多脉冲误差反向传播算法在各种学习情况下,对一系列学习任务的学习过程。通过不同的脉冲序列的学习验证对于不同的输入脉冲序列模式,脉冲神经网络能够训练出理想的脉冲序列模式。

下面通过三个模拟实验来验证该算法的学习能力。首先,第一个实验模拟了该算法在不同学习模式下对单脉冲序列的学习能力。其次,在第二个实验中我们把学习任务扩展到多脉冲序列模式,模拟了该算法在不同学习模式下对多目标脉冲序列的学习能力。最后,实验模拟了该算法对不同任务的脉冲序列的学习能力。

首先,选取第 1.3 节提到的前馈脉冲神经网络和 SRM 神经元模型作模拟实验。实验中,选取的网络参数为:阈值 $\theta=1$,神经元突触后电位的时间常量 $\tau=10$ ms,神经元不应期的时间常量 $\tau_R=35$ ms,学习率 $\eta=0.000001$,时间步长为 0.1ms。每一个新的输入脉冲模式输入到网络之前,隐含层和输出层中所有神经元的静息电位设置为 0。其次,多脉冲神经网络突触的初始化类似于单脉冲神经网络,任意两个不同层神经元之间突触的权值在 $[0, 0.2]$ 区间内随机生成,每一次试验都初始化突触权值。最后,模拟实验中所有的输入脉冲模式都是随机顺序,每次试验的最大迭代次数为 1000 次,且实验结果都是运行 50 次试验的平均值。

3.1 单脉冲序列学习任务

该实验的目的是为了说明该算法学习单脉冲序列任务的能力。任务是模拟多个输入脉冲序列模式映射到一个单目标脉冲序列的学习过程。首先,实验中采用了 3-10-1 的 SNN 网络结构,如图 3.1 所示。其中隐含层包含一个抑制性神经元,只产生负的突触后电位。其次,每个神经元之间的连接由 5 个突触组成,每个突触的延时固定为 1 到 5ms。最后,每个输入脉冲序列 $S_h^in(t)$ ($h=1, 2, 3$) 和目标脉冲序列 $S^d(t)$ 均由区间 $[0, 200\text{ms}]$ 随机产生的脉冲组成,如图 3.2 所示。

图 3.3 显示当输入脉冲序列输入到脉冲神经网络后,输出层神经元发放的实际脉冲序列 $S_j^o(t)$,以及经过误差反向传播学习过程后,输出层神经元发放的脉冲序列 $\hat{S}_j^o(t)$ 。图 3.4 显示了实验过程中平均误差函数值变化曲线,误差函数值变化曲线开始时出现了一个加快减小的过程,迭代到第 50 步后出现了较长的一段震荡区域,到第 357 步时误差值为 0.76。图 3.5 和 3.6 分别显示了学习过程前后突触权值的变化。从这个简单的实验中,证明了我们提出的多脉冲定时误差函

数在误差反向传播学习过程中能够训练出一个理想的目标。




图 3.1 单脉冲序列学习网络




图 3.2 3 个不同的输入脉冲序列




图 3.3 训练前输出脉冲序列、目标脉冲序列和训练后输出脉冲序列




图 3.4 误差变化曲线和标准差




图 3.5 学习过程之前的突触权值




图 3.6 学习过程之后的突触权值

3.2 多脉冲序列学习任务

该实验的目的是为了说明该算法学习多脉冲序列任务的能力。任务是模拟一个输入脉冲序列模式映射到多个目标脉冲序列的学习过程。首先，下面实验采取了 1-10-3 的 SNN 网络结构，如图 3.7 所示。另外，SNN 中其他参数的设置与第 3.1 节介绍的相同。

实验中，输入脉冲序列 $s_h^in(t)$ (图 3.8) 和目标脉冲序列 $s_j^d(t)$ ($j=1, 2, 3$) 也是分别由区间 $[0, 200\text{ms}]$ 随机产生的脉冲组成。图 3.9 显示当输入脉冲序列 $s_h^in(t)$ 进入到 SNN 后，输出层的 3 个不同神经元分别发放的实际脉冲序列 $s_j^o(t)$ ($j=1, 2, 3$)，然后，经过误差反向传播学习过程，输出层神经元分别发放的脉冲序列 $\hat{s}_j^o(t)$ ($j=1, 2, 3$)。从图 3.10 可以看出，实验过程中输出层 3 个神经元的平均误差函数值变化曲线，误差函数值变化曲线开始时也分别出现了一个不断减小的过程，紧接着出现了波动过程，但是误差值总和 E 不断减小的。最后，分别迭代到第 395、549、845 步时输出神经元 j ($j=1, 2, 3$) 输出的脉冲序列的误差值分别为 1.18、1.37、1.67。图 3.11 和图 3.12 分别显示了学习过程前后突触权值的变化。从实验中可以看出，本文提出的多脉冲定时误差函数在误差反向传播学习过程中能够训练出多个理想的目标。



图 3.7 多脉冲序列学习网络




图 3.8 输入脉冲序列

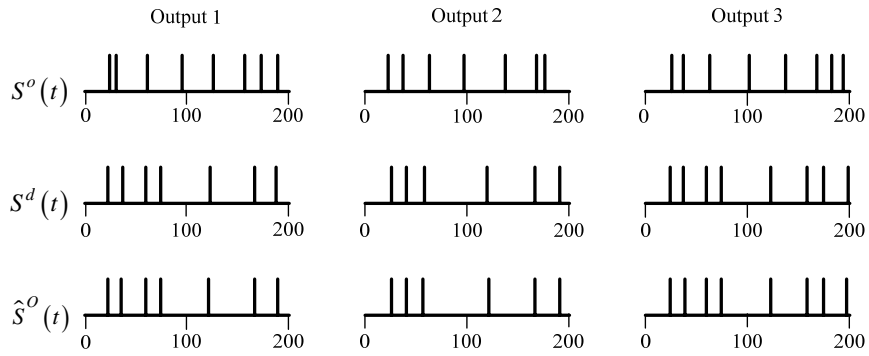


图 3.9 训练前输出脉冲序列、目标脉冲序列和训练后输出脉冲序列




图 3.10 3 个不同输出神经元的误差变化曲线和标准差




图 3.11 学习过程之前的突触权值




图 3.12 学习过程之后的突触权值

3.3 多任务脉冲序列学习任务

该实验的目的是为了说明该算法学习多任务脉冲序列任务的能力。任务是模拟多个不同输入脉冲序列模式分别映射到各自对应的目标脉冲序列的学习过程。首先，下面实验采取了 1-10-1 的 SNN 网络结构，如图 3.13 所示。另外，SNN 中其他参数的设置也与第 3.1 节介绍的相同。

实验中，输入脉冲序列包含不同的三个输入模式 $S^{in}(t)$ = #1、#2、#3，每个输入模式分别由区间[0, 200ms]随机产生的脉冲组成，并且每一个输入模式分别对应一个目标脉冲序列。图 3.14 显示当不同的输入脉冲模式 $S^{in}(t)$ 进入到 SNN 后，输出层的神经元会分别对应发放不同的实际脉冲序列 $S^o(t)$ ，分别与目标脉冲序列 $S^d(t)$ 进行比较，然后，通过误差反向传播算法对突触权值进行调整。从图 3.15 可以看出，实验过程中不同的输入脉冲序列模式对应的输出脉冲序列的平均误差函数值变化曲线，误差函数值变化曲线开始时分别出现了一个快速减小的过程，紧接着出现了波动过程，但是每个模式的误差 E 是不断减小的。然后，分别迭代到第 587、612、756 步后，对于三个不同的输入模式，输出神经元的输出的脉冲序列的误差值分别为 1.26、1.41、1.94。图 3.16 和 3.17 分别显示了学习过程前后突触权值的变化。从实验中可以看出，本文提出的多脉冲定时误差函数在误差反向传播学习过程中能够对多个任务训练出理想的目标。




图 3.13 多任务脉冲序列学习网络

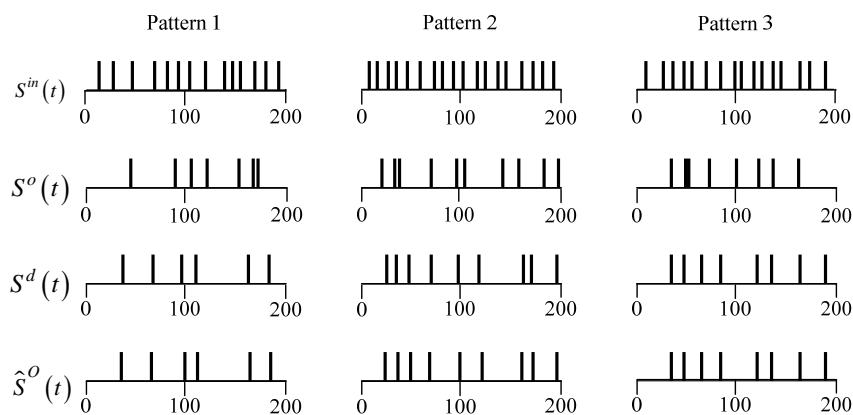


图 3.14 三个不同模式的输入脉冲序列、训练前输出脉冲序列、目标脉冲序列和训练后输出脉冲序列




图 3.15 3 个不同模式输出神经元的误差变化曲线和标准差




图 3.16 学习过程之前的突触权值




图 3.17 学习过程之后的突触权值

3.4 小结

本章结合多脉冲定时误差反向传播算法，分别对单脉冲序列、多脉冲序列以及多任务脉冲序列任务的学习能力及过程进行详细分析。实验结果表明了该算法在给定不同的输入模式下，通过误差反向传播学习过程中突触权值的调整，能够训练出理想的目标脉冲序列，实现了对脉冲序列复杂时空模式的学习。

4 非线性模式分类问题

本章通过非线性模式分类问题展示了多脉冲定时误差反向传播算法对于脉冲序列的非线性分类学习过程。

下面通过两个模拟实验来验证该算法对实际的非线性模式分类问题的求解能力。首先，模拟了该算法分别在不同学习模式下对 Fisher Iris 分类以及 Wisconsin 乳腺癌基准分类问题的学习能力。其次，分析了在多脉冲神经网络中突触个数、隐藏层神经元个数两个参数对该算法学习能力的影响。

首先，该模拟实验也采用了第 1.3 节介绍的前馈型脉冲神经网络和 SRM 神经元模型。实验中，选取的网络参数为：阈值 $\theta=1$ ，神经元突触后电位的时间常量 $\tau=10\text{ ms}$ ，神经元不应期的时间常量 $\tau_R=35\text{ ms}$ ，学习率 $\eta=0.0000002$ ，时间步长为 1ms 。每一个新的输入脉冲模式输入到网络之前，隐含层和输出层中所有神经元的静息电位设置为 0。其次，多脉冲神经网络突触的初始化类似于单脉冲神经网络，任意两个不同层神经元之间突触的权值在 $[0, 0.2]$ 区间内随机生成，每一次试验都初始化突触权值。最后，模拟实验中，每次试验的最大迭代次数为 500 次，且实验结果都是运行 50 次试验的平均值。

4.1 Fisher Iris 分类问题

Fisher Iris 数据集也是模式分类中常用到的基准数据集，该数据集包含三种不同的鸢尾花，每类花有 50 个样本，共由 150 个样本组成。每个样本代表花的 4 种属性：萼片长度、萼片宽度、花瓣长度和花瓣宽度。

4.1.1 实验过程

从 Fisher Iris 数据集的三类花中随机取 10 个样本（共 30 个样本）组成训练集，每类花中剩余的 40 个样本（共 120 个样本）组成测试集。在实验中，输入特征值采用了线性编码方案。首先，每个样本的 4 个特征值先根据四舍五入法转化成整数，然后分别归一化并线性编码在 $[10, 40\text{Hz}]$ 的频率范围内。然后，把每个频率值转化为 $[0, 100\text{ms}]$ 区间内的脉冲序列。最后，每个样本的 4 个特征值分别编码成了 4 个线性输入脉冲序列。输出值 1、2 和 3 分别编码成一个 10Hz、15Hz 和 20Hz 的目标脉冲序列。实验中规定每一个训练样本的输出脉冲序列的脉冲个数大于该类规定的发放的脉冲个数时，被认为训练样本正确分类，反之被认为错

误分类。

接下来的实验采用了 4-8-1 的 SNN 网络结构。其中隐含层也包含一个抑制性神经元，只产生负的突触后电位。每个神经元之间的连接由 5 个突触组成，每个突触的延时固定为 1 到 5ms。接下来第 4.1.2 节对突触个数和隐含层神经元个数分别进行详细介绍。图 4.1 显示了训练集在学习过程中分类错误的样本个数变化曲线。它开始时误差迅速减小，然后出现了波动过程，随后出现了一段平滑区域，最后，Fisher Iris 训练集样本分类错误的个数分别为 0.20、0.13 和 0.19。

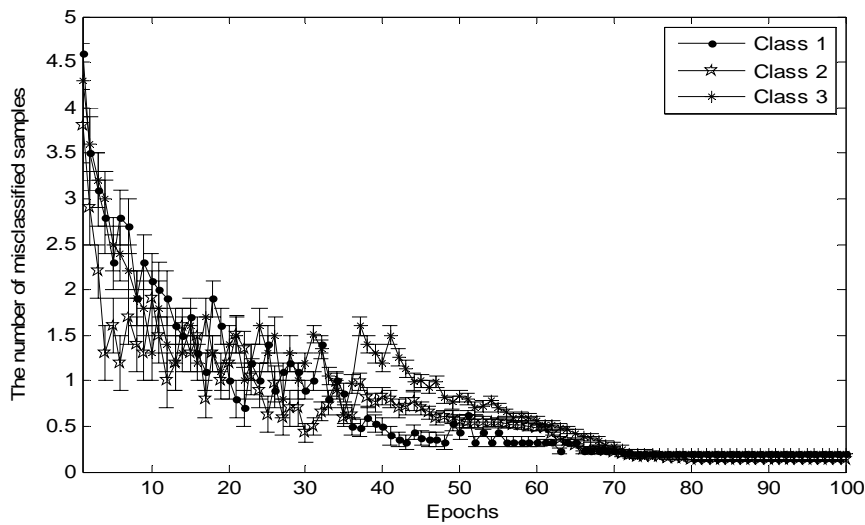


图 4.1 训练集误差变化曲线

文献[3]中提出的 SpikeProp 算法类似 ANN 中的基本 BP 算法，是一种适用于前馈脉冲神经网络误差反向传播的监督学习算法。实验中采用了一个 64-15-2 的全连接前馈型网络结构，该算法采用了 Time-to-first-spike 数据编码方法，只允许网络中的每个神经元发放一个脉冲，这样可以克服神经元内部状态变量发放脉冲而导致的不连续性，也可以忽略一个脉冲产生后神经元状态的变化。另外文中基于 SpikeProp 算法相同的条件下，在 Matlab v5.3 中运用 Sigmoid 神经网络对 LM 算法和 BP 算法也进行了实验测试，实验结果在表 4.1 中所示。

表 4.1 不同学习算法下 Fisher Iris 数据分类比较

算法	训练集	测试集
SpikeProp	97.4%±0.1	96.1%±0.1
Matlab BP	98.2%±0.9	95.5%±2.0
Matlab LM	99.0%±0.1	95.7%±0.1
Our method	99.6%±0.2	96.5%±0.3

表 4.1 说明本文提出的学习算法与其他现有的方法^[3,16]对于 Fisher Iris 分类问题进行了比较。然而，实验的结果显示训练集和测试集的分类正确率都优于其他算法。

4.1.2 实验参数分析

为了说明突触个数和隐含层神经元个数分别对该算法关于 Fisher Iris 数据集分类正确率的影响，接下来的两个实验分别进行详细的分析。

突触个数在 SNN 结构中是一个重要的因素。在实验中，分别对不同的突触个数进行了测试，结果显示突触个数为 5 时，数据集和测试集的分类准确率最高。当突触个数很小时，有一个比较低的分类准确率。但是随着突触个数的增加，网络的复杂度和运行时间也随着增加，而分类的准确率不断减小，如图 4.2 所示。这说明了突触个数越多不一定使算法的学习能力更强。

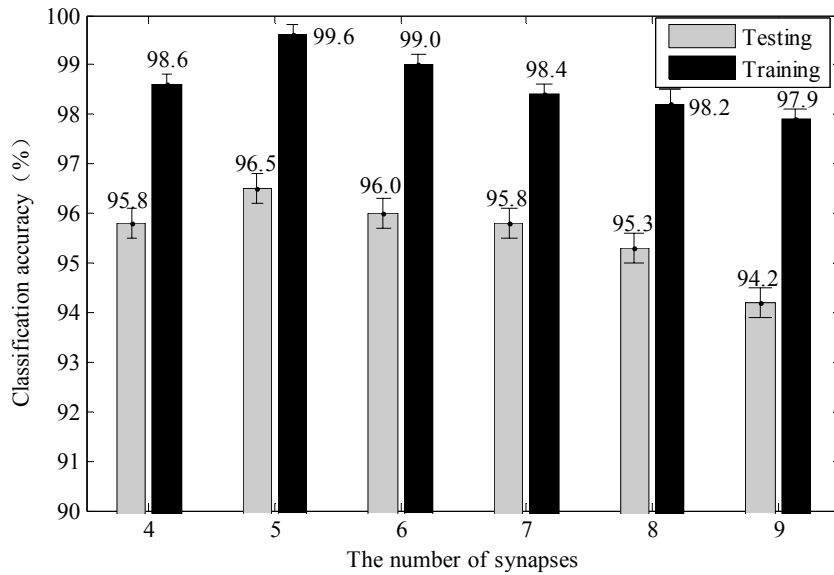


图 4.2 不同突触个数的分类准确率比较

隐含层神经元的个数决定着 SNN 的拓扑结构，为了研究不同的拓扑结构对本文提出的算法学习能力的影响。实验中隐含层神经元个数选择了 6 到 10 不同的五个数值进行测试。从实验结果可以看出，随着隐含层神经元个数的增加，数据集和测试集的分类准确度不断增加。然而，隐含层神经元个数超过 8 后分类准确度不断减少，如图 4.3 所示。

通过对上面两个参数的实验分析，说明了突触个数和隐含层神经元个数对该算法的学习能力影响很大，当突触个数和隐含层神经元个数分别为 5 和 8 时，算法的学习能力最强，而不是越大越好。




图 4.3 隐含层不同神经元个数的分类准确率比较

4.2 Wisconsin 乳腺癌分类问题

Wisconsin 乳腺癌数据集^[39]是在模式分类领域常被用到的基准数据集。该数据集包含 699 个样本，分别由 458 个代表良性和 241 个代表恶性的样本组成。其中数据集有 16 个样本丢失数据，并将这些样本删除。每个样本由 9 个特征值和 1 个输出值组成，每个特征值分别由范围[1, 10]内的整数表示，输出值 2 和 4 分别代表良性和恶性。通过乳腺肿瘤患者的肿瘤块的大小等 9 个特征值，判断此肿瘤为良性还是恶性。

4.2.1 实验过程

Wisconsin 乳腺癌数据集被随机分为两组，一组由 409 个样本组成为训练集，另一组由 274 个样本组成为测试集。在实验中，输入特征值采用了线性编码方案。首先，每个样本的 9 个特征值分别归一化并线性编码在[10, 40 Hz]的频率范围内。然后，把每个频率值转化为[0, 200ms]区间内的脉冲序列，最后，每个样本的 9 个特征值分别编码成了 9 个线性输入脉冲序列。输出值 2 和 4 分别编码成一个 30Hz 和 40Hz 的目标脉冲序列。实验中规定每一个训练样本的输出脉冲序列的脉冲个数大于该类规定的发放的脉冲个数时，被认为训练样本正确分类，反之被认为错误分类。

该实验采用了 9-10-1 的 SNN 网络结构。其中隐含层也包含一个抑制性神经

元，只产生负的突触后电位。每个神经元之间的连接由 5 个突触组成，每个突触的延时固定也为 1 到 5ms。图 4.4 显示了训练集在学习过程中分类错误的样本个数变化曲线。最后，Wisconsin 乳腺癌训练集样本分类错误的个数分别为 1.33（良性）和 1.56（恶性）。




图 4.4 训练集误差变化曲线

另外，文献[16]在模糊脉冲神经网络(Fuzzy Spiking Neural Networks, FSNN)中，提出了一种基于模糊推理的监督学习算法。首先，在 FSNN 中采用三层前馈型网络结构，所有的突触都是动态的，输入层的数据采用一个线性编码方案。其次，神经元用感受野(Receptive Field, RF)对不同的脉冲序列频率进行选择，RF 类似于 FSNN 中的模糊隶属度函数。通过模糊 C 均值聚类理论确定 RF 的位置使输入特征数据分到各自的类中，然后利用遗传算法产生最优的的集群和集群的宽度。最后，通过 ReSuMe 算法对输出脉冲序列进行学习，调整突触的权值，使输出层神经元训练出一个理想的结果，实验结果在表 4.2 中所示。

表 4.2 不同学习算法下 Wisconsin 乳腺癌数据分类比较

算法	训练集	测试集
SpikeProp	97.6%±0.2	97.0%±0.6
Matlab BP	98.1%±0.4	96.3%±0.6
Matlab LM	97.7%±0.3	96.7%±0.6
ReSuMe	98.4%±0.45	96.5%±1.04
Our method	99.2%±0.2	97.9%±0.3

对于 Wisconsin 乳腺癌分类问题，本文提出的学习算法与 4.1.1 节提到的其他方法以及文献[16]提到的算法进行了比较，如表 4.2 所示。然而，实验的结果显

示训练集和测试集的分类正确率也都优于其他算法。

4.2.2 实验参数分析

为了说明突触个数和隐含层神经元个数分别对该算法关于 Wisconsin 乳腺癌数据集分类正确率的影响,我们做了类似于 Fisher Iris 分类问题的参数分析实验。

实验中,分别对不同的突触个数进行了测试,结果显示突触个数为 5 时,数据集和测试集的分类准确率最高。当突触个数很小时,实验也会有一个比较低的分类准确率。但是随着突触个数的增加,网络的复杂度和运行时间也随着增加,而分类的准确率不断减小,如图 4.5 所示。




图 4.5 不同突触个数的分类准确率比较

实验中隐含层神经元个数选择了 8 到 12 不同的五个数值进行测试。从实验结果可以看出,随着隐含层神经元个数的增加,数据集和测试集的分类准确度不断增加,然而,隐含层神经元个数超过 10 后分类准确度不断减少,如图 4.6 所示。

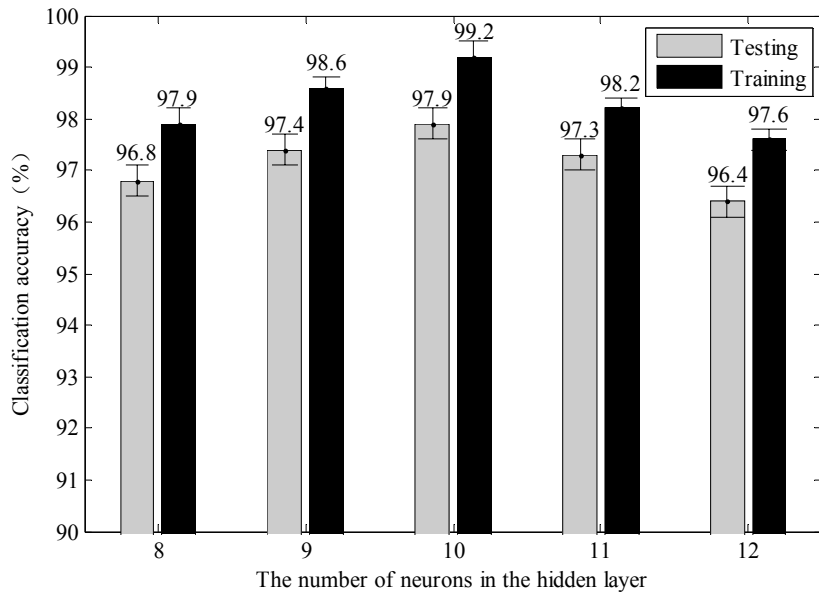


图 4.6 隐含层不同神经元个数的分类准确率比较

通过对上面两个参数的实验分析，当突触个数和隐含层神经元个数分别为 5 和 10 时，该算法对 Wisconsin 乳腺癌数据集的分类正确率最高。

4.3 小结

本章将多脉冲定时误差反向传播算法应用到实际的非线性模式分类问题，验证了该算法对非线性模式分类问题的求解能力。首先，结合线性编码信息的特点，分别对 Fisher Iris 数据集和 Wisconsin 乳腺癌数据集的数据进行编码，使该算法分别在不同学习模式下对 Fisher Iris 分类以及 Wisconsin 乳腺癌基准分类问题的进行学习，实验表明本文提出的学习算法对于训练集和测试集的分类正确率都优于其他算法。其次，分别对多脉冲神经网络中突触个数、隐藏层神经元个数两个参数进行了分析。实验结果显示突触个数和隐含层神经元个数会影响该算法的学习能力。

5 总结与展望

5.1 总结

人们对应用脉冲神经网络监督学习来模拟人类的认知过程、智能行为的研究已走过一段曲折的道路,虽然许多关键技术获得突破,但是,由于人类对脑的结构及功能,特别是大脑中神经系统信息处理方式的认知不足,使其得到广泛应用还很远。因此,本文针对多脉冲编码神经信息的特征,以及目前多层前馈脉冲神经网络误差反向传播算法研究中存在的问题,提出了一种新型的多脉冲定时误差函数,克服了脉冲神经网络中对输出层神经元仅能发放一个脉冲的限制,可使网络中所有层的神经元发放多个脉冲。结合该误差函数并设计脉冲神经网络多脉冲定时误差反向传播算法,提高应用脉冲神经网络解决复杂问题的能力。

本文在脉冲序列学习的实验中展示了多脉冲误差反向传播算法在各种学习情况下,对一系列学习任务的学习过程。首先,通过对单脉冲序列的学习验证了对于给定输入脉冲序列脉冲神经网络能够训练出一个理想的脉冲序列。其次,通过对多脉冲序列的学习展示了脉冲神经网络能够有效地学习不同的目标脉冲序列。最后,多任务脉冲序列的学习显示了脉冲神经网络对于不同的输入模式能够并行地完成多模式的学习。实验结果表明了该算法能够在误差反向传播学习过程中,对于不同的输入脉冲序列模式,脉冲神经网络通过误差反向传播学习过程中突触权值的调整,能够训练出理想的目标脉冲序列,实现了对脉冲序列复杂时空模式的学习。

本文将多脉冲定时误差反向传播算法应用到非线性模式分类问题,验证该算法对非线性模式分类问题的求解能力。首先,结合线性脉冲序列编码的特点,分别对 Fisher Iris 数据集和 Wisconsin 乳腺癌数据集的数据进行编码,使该算法分别在不同学习模式下对 Fisher Iris 分类以及 Wisconsin 乳腺癌基准分类问题的进行学习。实验表明多脉冲学习的分类准确率比单脉冲学习得到有效地提高。其次,分别对多脉冲神经网络中突触个数、隐藏层神经元个数两个参数进行了分析。实验结果显示突触个数和隐含层神经元个数会影响该算法的学习能力。

5.2 研究展望

对于多层前馈脉冲神经网络的监督学习的研究还处于起步阶段,在今后的研

究工作中，还可以在以下领域进行更加深入的研究：

(1) 定义更符合实际生物神经系统的多脉冲定时误差函数以及构建更有效的脉冲神经网络多脉冲定时误差反向传播算法，实现对脉冲序列复杂时空模式的学习。为脉冲神经网络的各种应用奠定坚实的理论基础和有力的技术支持，以推动脉冲神经网络技术的实用化进程。

(2) 将模拟数据转化为脉冲序列的精确定时编码方法的研究，特别是随时间变化的信息编码方法。

(3) 脉冲神经网络拓扑结构的研究，除了前馈型脉冲神经网络外，使脉冲神经网络监督学习应用到其他各种网络结构中。

(4) 脉冲神经元的研究，特别是在脉冲神经网络中对更符合实际生物神经系统的神经元研究。

参考文献

- [1] S. M. Bohte. The Evidence for Neural Information Processing with Precise Spike-Times: A Survey [J]. *Natural Computing*, 2004, 3(2): 195–206.
- [2] S. Ghosh-Dastidar, H. Adeli. Spiking Neural Networks [J]. *International Journal of Neural Systems*, 2009, 19(4): 295–308.
- [3] S. M. Bohte, J. N. Kok, J. A. La Poutre. Error-Backpropagation in Temporally Encoded Networks of Spiking Neurons [J]. *Neurocomputing*, 2002, 48(1-4): 17–37.
- [4] E. I. Knudsen. Supervised learning in the brain [J]. *Journal of Neuroscience*, 1994, 14(7): 3985–3997.
- [5] E. I. Knudsen. Instructed learning in the auditory localization pathway of the barn owl [J]. *Nature*, 2002, 417(6886): 322 – 328.
- [6] S. M. Bohte, J. N. Kok, J. A. La Poutre. Error-Backpropagation in Temporally Encoded Networks of Spiking Neurons [J]. *Neurocomputing*, 2002, 48(1-4): 17–37.
- [7] J. Xin, M. J. Embrechts. Supervised Learning with Spiking Neuron Networks [A] . In: *Proceedings of the International Joint Conference on Neural Networks [C]*. Washington D.C., 2001: 1772–1777.
- [8] B. Schrauwen, J. Van Campenhout. Extending SpikeProp [A]. In: *Proceedings of the International Joint Conference on Neural Networks [C]*. Budapest, Hungary, 2004: 471–475.
- [9] S. McKeenoch, D. Liu, L. Bushnell. Fast Modifications of the SpikeProp Algorithm [A]. In: *Proceedings of the International Joint Conference on Neural Networks [C]*. Vancouver, Canada, 2006: 3970–3977.
- [10] S. McKeenoch, T. Voegtlin, L. Bushnell. Spike-Timing Error Backpropagation in Theta Neuron Networks[J]. *Neural computation*, 2009, 21(1): 9–45.
- [11] T. Wakamatsu, H. Takase, H. Kawanaka, S. Tsuruoka. A Training Algorithm for SpikeProp Improving Stability of Learning Process [A]. In: *Proceedings of the International Joint Conference on Neural Networks [C]*. San Jose, CA, 2011: 951–955.
- [12] O. Booi, H. tat Nguyen. A Gradient Descent Rule for Spiking Neurons Emitting Multiple Spikes [J]. *Information Processing Letters*, 2005, 95(6): 552–558.
- [13] S. Ghosh-Dastidar, H. Adeli. A New Supervised Learning Algorithm for Multiple Spiking

- Neural Networks with Application in Epilepsy and Seizure Detection [J]. *Neural Networks*, 2009, 22(10): 1419–1431.
- [14] F. Ponulak, A. Kasiński. Supervised Learning in Spiking Neural Networks with ReSuMe: Sequence Learning, Classification, and Spike Shifting [J]. *Neural Computation*, 2010, 22(2): 467–510.
- [15] A. Grüning, I. Sporea. Supervised Learning of Logical Operations in Layered Spiking Neural Networks with Spike Train Encoding [J]. *Neural Processing Letters*, Oct 2012, 36(2): 117-134.
- [16] C. Glackin, L. Maguire. L. McDaid, H. Sayers. Respective Field Optimization and Supervision of A Fuzzy Spiking Neural Network [J]. *Neural Networks*, 2011, 24: 247–256.
- [17] I. Sporea, A. Grüning. Supervised Learning in Multilayer Spiking Neural Networks. Submitted for Publication. Preprint available online at: <http://arxiv.org/cs/1202.2249>.
- [18] A. V. M. Herz, T. Gollisch, C. K. Machens, et al. Modeling Single-Neuron Dynamics and Computations: A Balance of Detail and Abstraction [J]. *Science*, 2006, 314(5796): 80-85.
- [19] W. Rall. Branching Dendritic Trees and Motoneuron Membrane Resistivity [J]. *Experimental Neurology*, 1959, 1(5): 491-527.
- [20] H. Agmon-Snir, C. E. Carr, Rinzel J. The Role of Dendrites in Auditory Coincidence Detection [J]. *Nature*, 1998, 393(6682): 268-272.
- [21] E. Fransen, B. Tahvildari, A. V. Egorov, et al. Mechanism of Graded Persistent Cellular Activity of Entorhinal Cortex Layer V Neurons [J]. *Neuron*, 2006, 49(5): 735-746.
- [22] A. L. Hodgkin, A. F. Huxley. Currents Carried by Sodium and Potassium Ions Through the Membrane of the Giant Axon of Loligo [J]. *The Journal of Physiology*, 1952, 116(4): 449- 472.
- [23] A. L. Hodgkin, A. F. Huxley. A Quantitative Description of Membrane Current and Its Application to Conduction and Excitation in Nerve [J]. *The Journal of Physiology*, 1952, 117(4): 500-544.
- [24] R. D. Traub, R. Miles. *Neuronal Networks of the Hippocampus* [M]. Cambridge UK Cambridge University Press, 1991.
- [25] L. Lapicque. Recherches Quantitatives Sur L’excitation Électrique Des Nerfs Traitée Comme Une Polarization [J]. *Journal de Physiologie et Pathologie General*, 1907, 9: 620-635.
- [26] E. M. Izhikevich. Resonate-and-Fire Neurons [J]. *Neural Networks*, 2001, 14(6/7): 883-894.

- [27] W. Gerstner, W. M. Kistler. Spiking Neuron Models: Single Neurons, Populations, Plasticity [M]. Cambridge: Cambridge University Press, 2002.
- [28] W. Gerstner. Spiking Neurons[A]. In: W. Maass and C. M. Bishop.(eds.). Pulsed Neural Networks[M]. Cambridge: MIT Press, 1999: 3-54.
- [29] S. Grillner, H. Markram, E. D. Schutter, G. Silberberg, F. E. LeBeau. Microcircuits in Action—from CPGs to Neocortex [J]. TRENDS in Neurosciences, 2005, 28(10): 525–533.
- [30] E. Bienenstock. A Model of Neocortex [J]. Network: Computation in Neural Systems, 1995, 6: 179–224.
- [31] W. Maass, T. Natschlaeger, H. Markram. Real-Time Computing Without Stable States: A New Framework for Neural Computation Based on Perturbations[J]. Neural Computation, 2002, 14(11): 2531–2560.
- [32] W. Maass, T. Natschlaeger, H. Markram. Computational Models for Generic Cortical Microcircuits[A]. In: J. Feng, editor, Computational Neuroscience: A Comprehensive Approach[M], Chapman and Hall/CRC, Boca Raton, 2004: 575–605.
- [33] S. Thorpe, D. Fize, C. Marlot. Speed of Processing in the Human Visual System [J]. Nature, 1996, 381(6582): 520-522.
- [34] J. J. Hopfield. Pattern Recognition Computation Using Action Potential Timing for Stimulus Representation [J]. Nature, 1995, 376: 33-36.
- [35] W. Maass, C. M. Bishop. Pulsed Neural Networks [M]. MA: Bradford Books/MIT Press, 2001.
- [36] 沈虹. Spiking 神经网络及其应用研究[D]. 南京: 南京工业大学, 2006:
- [37] 方慧娟, 王永骥. 多脉冲发放的 Spiking 神经网络[J]. 应用科学学报, 2008, 26 (6): 638-644.
- [38] Jie Yang, Wenyu Yang, Wei Wu. A Remark on the Error-Backpropagation Learning Algorithm for Spiking Neural Networks [J]. Applied Mathematics Letters, 2012, 25(2012): 1118-1120.
- [39] A. Asuncion, D. J. Newman. UCI Machine Learning Repository[OL], available: <http://www.ics.uci.edu/~mllearn/MLRepository.html>, 2012-9-29.

攻读硕士期间学术成果

- [1] 蔺想红; 巩祖正. 单房室脉冲神经元建模方法综述[J]. 计算机工程与应用, 2011, 47(35): 41-44.
- [2] Xianghong Lin, Zuzheng Gong. Supervised Learning in Spiking Neural Networks with Multiple Spikes Error Backpropagation[J]. Neural Computation, (submitted).

致谢

值此论文完成之际，首先要衷心感谢我的导师蔺想红副教授。研究生期间，他对我悉心指导，使我的学术水平和科研能力有了一定的提高和进步，他严谨的治学态度、务实的工作作风以及积极的生活态度指导和督促着我不断进步。从论文的选题、开题到最后的论文修改和校对，每一个过程都离不开蔺老师的指导和帮助。在此向蔺老师给予我学习中的无私帮助，生活中的无微不至的关心以及做人做事的谆谆教导表示最诚挚的谢意和最崇高的敬意！

其次，要特别感谢计算机科学与工程学院冯百明教授、张志昌副教授以及王银柱老师，感谢他们在学习上、生活上对我的关心和帮助，在此向他们深表谢意。

另外，感谢三年研究生生活中我的舍友路振宇、张春华和葛昊，以及李志强等师弟们，陪伴我度过了这长久的学习、研究阶段，帮助我解决问题，开拓思想。感谢李旭、展旭升，杨鹏斐等我们班的所有同学，我们有幸相聚在一起，共同学习，互帮互助，共同进步。

感谢对论文进行评审并提出宝贵意见的各位专家。感谢本文引用文献中的所有作者。

最后，感谢我善良的父母在多年的学习和生活中，对我学业的支持与理解，他们给予了我无私的关怀和无尽的爱，父母的养育之恩我终身难忘！

感谢所有曾经给予我支持和帮助的人！